

ความน่าจะเป็นและสัญญาณสุ่ม (Probability & Random Signal)

ตอนที่ 1 : ความไม่แน่นอนในกรณีที่แย่ที่สุด (Worst case Uncertainty)

ความไม่แน่นอน (uncertainty) เห็นพบได้ในระบบทางกายภาพทั่วไป บางระบบนั้นอาจจะได้รับผลกระทบจากความไม่แน่นอนมากกว่าระบบอื่น นั่นหมายความว่าผลตอบสนองของระบบนั้นสามารถเป็นได้หลากหลาย เราจึงจำเป็นต้องระบุความไม่แน่นอนในระบบเท่าที่ทำได้ และ ออกแบบตัวกรอง ระบบประมาณค่า หรือ ระบบควบคุม ที่จัดการความไม่แน่นอนนั้น

หนึ่งค่าที่บ่งบอกถึงลักษณะสำคัญของระบบคือพารามิเตอร์ (parameter) ซึ่งเป็นค่าคงที่ในระบบ ปัญหาในการวิเคราะห์หรือการออกแบบคือการที่เราไม่ทราบค่าที่แน่ชัดของค่าคงที่เหล่านี้ ดังนั้นเราสามารถเขียนค่าคงที่และบอกขอบเขตความไม่แน่นอนของค่าเหล่านี้ได้ดังนี้

$$e = \hat{e} \pm \delta e$$

โดยที่

e คือค่าของพารามิเตอร์

\hat{e} คือค่าประมาณที่ดีที่สุด (best estimate)

δe คือค่าความไม่แน่นอนสัมบูรณ์ที่มีค่ามากที่สุดซึ่งมีหน่วยเดียวกันกับค่า \hat{e} ซึ่งจะเป็นค่าบวกเสมอ

ความไม่แน่นอนที่เขียนในรูปบวกกลบนั้นระบุถึงกรณีที่แย่ที่สุด (worst case) จะเกิดขึ้นได้จริง ดังนั้นค่าที่มีความไม่แน่นอนนี้จะอยู่ในช่วง $[\hat{e} - \delta e, \hat{e} + \delta e]$

การอธิบายความไม่แน่นอนในลักษณะดังกล่าวมีข้อดีในเรื่องของการออกแบบและวิเคราะห์ให้ครอบคลุม เราสามารถออกแบบระบบที่คงทน (robust) และทำงานอยู่ในช่วงได้

การบวกกลบกันของความไม่แน่นอน

กำหนดให้ชิ้นงาน 2 ชิ้นวางต่อกันโดยที่ชิ้นงานแรกมีความยาวเท่ากับ $\hat{e}_1 \pm \delta e_1$ ชิ้นงานอีกชิ้นหนึ่งมีความยาวเท่ากับ $\hat{e}_2 \pm \delta e_2$ ดังนั้นหากเราเอาชิ้นงานวางต่อกัน ความยาวสูงสุดของชิ้นงานที่เป็นไปได้ e_{\max} สามารถเขียนได้ดังต่อไปนี้

$$e_{\max} = (\hat{e}_1 + \delta e_1) + (\hat{e}_2 + \delta e_2)$$

ความยาวต่ำสุดของชิ้นงานที่เป็นไปได้ e_{\min} เป็นดังต่อไปนี้

$$e_{\min} = (\hat{e}_1 - \delta e_1) + (\hat{e}_2 - \delta e_2)$$

หากเราเขียนอยู่ในรูป \pm เราจะสามารถเขียนได้ดังต่อไปนี้

$$e = (\hat{e}_1 + \hat{e}_2) \pm \frac{e_{\max} - e_{\min}}{2}$$

$$e = (\hat{e}_1 + \hat{e}_2) \pm \frac{(\hat{e}_1 + \delta e_1) + (\hat{e}_2 + \delta e_2) - (\hat{e}_1 - \delta e_1) - (\hat{e}_2 - \delta e_2)}{2}$$

$$e = (\hat{e}_1 + \hat{e}_2) \pm \frac{2(\delta e_1 + \delta e_2)}{2}$$

$$e = (\hat{e}_1 + \hat{e}_2) \pm (\delta e_1 + \delta e_2)$$

เมื่อนำค่ามาบวกรวมกัน ความไม่แน่นอนของแต่ละค่าก็จะเอามารวมกันด้วยเช่นกัน

ในกรณีที่เรามีชิ้นงานที่มีความยาว $\hat{e}_1 \pm \delta e_1$ เราทำการใช้เครื่องมือวัดชิ้นส่วนโดยวัดจากขอบไปเป็นความยาว $\hat{e}_2 \pm \delta e_2$ เราจะหาความยาวของชิ้นงานที่โดนตัดได้ดังต่อไปนี้

$$e_{\max} = (\hat{e}_1 + \delta e_1) - (\hat{e}_2 - \delta e_2)$$

$$e_{\min} = (\hat{e}_1 - \delta e_1) - (\hat{e}_2 + \delta e_2)$$

หากเราเขียนอยู่ในรูป \pm เราจะสามารถเขียนได้ดังต่อไปนี้

$$e = (\hat{e}_1 - \hat{e}_2) \pm \frac{p_{\max} - p_{\min}}{2}$$

$$e = (\hat{e}_1 - \hat{e}_2) \pm \frac{(\hat{e}_1 + \delta e_1) - (\hat{e}_2 - \delta e_2) - (\hat{e}_1 - \delta e_1) + (\hat{e}_2 + \delta e_2)}{2}$$

$$e = (\hat{e}_1 - \hat{e}_2) \pm \frac{2(\delta e_1 + \delta e_2)}{2}$$

$$e = (\hat{e}_1 - \hat{e}_2) \pm (\delta e_1 + \delta e_2)$$

ถึงแม้ว่าเราจะนำค่าสองค่ามาลบกัน แต่ความไม่แน่นอนจะถูกรวมกัน

การคูณและหารกันของความไม่แน่นอน

แทนที่เราจะวิเคราะห์ความไม่แน่นอนในเชิงสัมบูรณ์ เราสามารถวิเคราะห์ความไม่แน่นอนแบบสัมพัทธ์ $\delta^r e$ ได้ (relative uncertainty) ซึ่งสามารถคำนวณได้ตามความสัมพันธ์ดังต่อไปนี้

$$\delta^r e = \frac{\delta e}{|\hat{e}|}$$

โดยที่ \hat{e} คือความไม่แน่นอนสัมพัทธ์ของค่า e

สมมติว่าแผนชิ้นงานถูกกำหนดมาให้มีรูปร่างเป็นสี่เหลี่ยมผืนผ้าที่มีความยาวเท่ากับ $\hat{e}_1 \pm \delta e_1$ และมีความยาวเท่ากับ $\hat{e}_2 \pm \delta e_2$ หากเราต้องการหาพื้นที่หรือผลคูณระหว่างความยาวและความกว้าง เราสามารถหาความไม่แน่นอนจากการรวมกันของความไม่แน่นอนสัมพัทธ์ซึ่งเขียนเป็นสมการได้ดังต่อไปนี้

$$\frac{\delta e}{|\hat{e}|} = \frac{\delta e_1}{|\hat{e}_1|} + \frac{\delta e_2}{|\hat{e}_2|}$$

$$\hat{e} \pm \delta e = (\hat{e}_1 \cdot \hat{e}_2) \pm |\hat{e}_1 \cdot \hat{e}_2| \cdot \frac{\delta e_1}{|\hat{e}_1|} + |\hat{e}_1 \cdot \hat{e}_2| \frac{\delta e_2}{|\hat{e}_2|}$$

$$\hat{e} \pm \delta e = (\hat{e}_1 \cdot \hat{e}_2) \pm \left| \frac{\hat{e}_1 \cdot \hat{e}_2}{\hat{e}_1} \right| \cdot \delta e_1 + \left| \frac{\hat{e}_1 \cdot \hat{e}_2}{\hat{e}_2} \right| \cdot \delta e_2$$

$$\hat{e} \pm \delta e = (\hat{e}_1 \cdot \hat{e}_2) \pm |\hat{e}_2| \cdot \delta e_1 + |\hat{e}_1| \cdot \delta e_2$$

สมมติว่าเราต้องการคำนวณความชันของเส้น โดยกำหนดความต่างในแนวตั้งเป็น $e_1 \pm \delta e_1$ และ ความต่างในแนวนอนเป็น $e_2 \pm \delta e_2$ เราสามารถหาผลหารได้ในลักษณะเดียวกันกับผลคูณซึ่งเขียนเป็นสมการได้ดังต่อไปนี้

$$\frac{\delta e}{|\hat{e}|} = \frac{\delta e_1}{|\hat{e}_1|} + \frac{\delta e_2}{|\hat{e}_2|}$$

$$\begin{aligned}\hat{e} \pm \delta e &= \left(\frac{\hat{e}_1}{\hat{e}_2} \right) \pm \left| \frac{\hat{e}_1}{\hat{e}_2} \right| \cdot \frac{\delta e_1}{|\hat{e}_1|} + \left| \frac{\hat{e}_1}{\hat{e}_2} \right| \cdot \frac{\delta e_2}{|\hat{e}_2|} \\ \hat{e} \pm \delta e &= \left(\frac{\hat{e}_1}{\hat{e}_2} \right) \pm \left| \frac{\hat{e}_1}{\hat{e}_1 \cdot \hat{e}_2} \right| \cdot \delta e_1 + \left| \frac{\hat{e}_1}{\hat{e}_2^2} \right| \cdot \delta e_2 \\ \hat{e} \pm \delta e &= \left(\frac{\hat{e}_1}{\hat{e}_2} \right) \pm \frac{1}{\hat{e}_2^2} \cdot (|\hat{e}_2| \cdot \delta e_1 + |\hat{e}_1| \cdot \delta e_2)\end{aligned}$$

ผลรวมเชิงเส้น (Linear Combination)

กำหนดให้ค่าที่ต้องคำนวณสามารถเขียนในรูปของผลรวมเชิงเส้น (linear combination) ได้ดังต่อไปนี้

$$\begin{aligned}e &= a_1 \cdot (\hat{e}_1 \pm \delta e_1) + a_2 \cdot (\hat{e}_2 \pm \delta e_2) + \dots \\ e &= \sum_{k=1}^n \{a_k \cdot (\hat{e}_k \pm \delta e_k)\}\end{aligned}$$

โดยที่ a_k อาจจะเป็นบวกหรือลบก็ได้

เราสามารถหาค่าความคลาดเคลื่อนได้ดังต่อไปนี้

$$e = \sum_{k=1}^n \{a_k \cdot \hat{e}_k\} \pm \sum_{k=1}^n \{|a_k| \cdot \delta e_k\}$$

การยกกำลังของความไม่แน่นอน

หากเรามีค่าที่มีความไม่แน่นอนที่โดนยกกำลัง เราสามารถหาความไม่แน่นอนได้โดยทำการคูณความไม่แน่นอนสัมพัทธ์เดิมด้วยเลขยกกำลัง

$$\begin{aligned}p &= (\hat{e} \pm \delta e)^n \\ \frac{\delta p}{|\hat{p}|} &= |n| \frac{\delta e}{|\hat{e}|} \\ \delta p &= |n \hat{e}^{n-1}| \delta e\end{aligned}$$

การประมาณความไม่แน่นอนด้วยอนุพันธ์

ในกรณีที่ความสัมพันธ์เป็นฟังก์ชันไม่เชิงเส้น เราสามารถประมาณความไม่แน่นอนจากนิยามของอนุพันธ์ กำหนดให้ความสัมพันธ์เป็นดังต่อไปนี้

$$p = f(e)$$

เราสามารถประมาณความไม่แน่นอนได้โดยใช้นิยามดังต่อไปนี้

$$\frac{\delta p}{\delta e} \approx \left| \frac{d}{d e} (f(e)) \right|_{e=\hat{e}}$$

ดังนั้นเราจะได้ความสัมพันธ์ดังต่อไปนี้

$$p \approx \hat{e} \pm \left| \frac{d}{d e} (f(e)) \right|_{e=\hat{e}} \cdot \delta e$$

เช่น

$$\cos(p) = \cos(\hat{e} \pm \delta e)$$

$$\cos(p) = \cos(\hat{e}) \pm \delta p = \cos(\hat{e}) \pm \left. \frac{d}{d e} \cos(e) \right|_{e=\hat{e}} \cdot \delta e$$

$$\cos(p) = \cos(\hat{e}) \pm |-\sin(\hat{e})| \cdot \delta e$$

การประยุกต์ใช้ความไม่แน่นอนของระบบ

เมื่อกล่าวถึงการจำลอง (simulation) คนส่วนมากมักจะคิดถึงการจำลองในอุดมคติที่มีค่าพารามิเตอร์ที่ชัดเจน แต่ในโลกความเป็นจริง เราอาจจะไม่สามารถทราบค่าที่ชัดเจนของพารามิเตอร์เหล่านี้ เพื่อที่จะจำลองให้มีลักษณะที่ครอบคลุมหรือใกล้เคียงกับการทดลองจริง เราสามารถประยุกต์ใช้ความไม่แน่นอนนี้ได้ หากเราสามารถกำหนดช่วงของพารามิเตอร์เหล่านี้ได้ เราจะสามารถจำลองเป็นจำนวนหลายครั้งได้โดยเปลี่ยนแปลงพารามิเตอร์ในช่วงความไม่แน่นอนที่คำนวณมา

ตัวอย่างที่ 1 : การจำลองพลวัต

ตัวอย่างนี้เป็นการทดลองเพื่อวัดหาเวลาที่ทำให้วัตถุหลุดจากความเร็วเชิงมุมที่คงที่ ω^*

วัตถุที่ถูกทำให้หมุนเป็นวัตถุทรงปริซึมสี่เหลี่ยมผืนผ้าซึ่งสามารถหาความถี่ในแนวแกนหมุนตามสมการดังต่อไปนี้

$$J = \frac{1}{12} m(a^2 + b^2) + ml^2$$

โดยที่

a และ b เป็นความกว้างและความยาวของวัตถุ $[m]$

l เป็นระยะห่างระหว่างจุดศูนย์กลางมวลและแกนในการหมุน $[m]$

m เป็นมวลของวัตถุ $[kg]$

นอกจากนี้ ระบบที่โดนหมุนได้เชื่อมต่อกับตัวสปริงที่มีความถี่เชิงมุมเท่ากับ $B \left[\frac{N \cdot m \cdot s}{rad} \right]$

และมีพลวัตตามสมการดังต่อไปนี้

$$J \cdot \frac{d}{dt}(\omega) = -B \cdot \omega$$

$$\omega(0) = \omega^*$$

เราจะนิยามระยะเวลาในการหยุดของวัตถุ T_s ให้เป็นระยะเวลาที่ความเร็วของวัตถุมีความเร็วเหลือแค่ 2% ของความเร็วเริ่มต้น

$$\omega(T_s) = 0.02 \cdot \omega^*$$

นอกจากลักษณะและความสัมพันธ์ของระบบและพารามิเตอร์ที่บอกมา ค่าต่างๆและความไม่แน่นอนถูกกำหนดมาดังนี้

พารามิเตอร์	ค่าของพารามิเตอร์	หน่วย
ω^*	60 ± 2.5	rpm
B	0.067 ± 0.034	$\frac{\text{N} \cdot \text{m} \cdot \text{s}}{\text{rad}}$
m	1.343 ± 0.001	kg
a	0.35 ± 0.005	m
b	0.25 ± 0.005	m
l	0.05 ± 0.005	m

หนึ่งในวิธีที่เราสามารถจำลองระบบให้ครอบคลุมได้คือการกำหนดให้พารามิเตอร์มีค่าที่เป็นได้

```

N = 11;
w_0 = 60+2.5*linspace(-1,1,N);
B = 0.067+0.034*linspace(-1,1,N);
m = 1.343+0.001*linspace(-1,1,N);
a = 0.35+0.005*linspace(-1,1,N);
b = 0.25+0.005*linspace(-1,1,N);
l = 0.05+0.005*linspace(-1,1,N);

```

หากเรากำหนดค่าพารามิเตอร์ในรูปแบบดังกล่าว เราจะต้องจำลองทั้งหมด 11^6 หรือมากกว่า **1.7** ล้านครั้ง แต่ถ้าหากเราหาความไม่แน่นอนและรวมพารามิเตอร์บางตัวได้ เราจะสามารถลดการคำนวณได้อีก เราทำการซ้พารามิเตอร์ของระบบให้เป็นดังต่อไปนี้

$$\frac{d}{dt}(\omega) = -\frac{1}{\tau} \cdot \omega$$

$$\tau = \frac{J}{B}$$

เราคำนวณค่าความไม่แน่นอนของพารามิเตอร์ K ได้ดังต่อไปนี้

$$\delta\tau = \hat{\tau} \cdot \left(\frac{\delta J}{\hat{J}} + \frac{\delta B}{\hat{B}} \right)$$

$$\delta J = \frac{1}{12} \delta\{m(a^2 + b^2)\} + \delta\{ml^2\}$$

$$\delta J = \frac{1}{12} \cdot [\hat{m} \cdot \delta\{(a^2 + b^2)\} + (\hat{a}^2 + \hat{b}^2) \cdot \delta m] + [\hat{m} \cdot \delta\{l^2\} + \hat{l}^2 \cdot \delta m]$$

$$\delta J = \frac{1}{12} \cdot [\hat{m} \cdot (2\hat{a} \cdot \delta a + 2\hat{b} \cdot \delta b) + (\hat{a}^2 + \hat{b}^2) \cdot \delta m] + [\hat{m} \cdot 2\hat{l} \cdot \delta l + \hat{l}^2 \cdot \delta m]$$

$$\delta J = \left(\frac{\hat{m}\hat{a}}{6} \right) \cdot \delta a + \left(\frac{\hat{m}\hat{b}}{6} \right) \cdot \delta b + \left(\frac{\hat{a}^2 + \hat{b}^2}{12} + \hat{l}^2 \right) \cdot \delta m + (2\hat{m}\hat{l}) \cdot \delta l$$

```

w_0_e = 60;
B_e = 0.067;
m_e = 1.343;
a_e = 0.35;
b_e = 0.25;
l_e = 0.05;

```

```

dw = 2.5;
dB = 0.034;
dm = 0.001;
da = 0.005;

```

```

db = 0.005;
dl = 0.005;

dJ = (m_e*a_e/6)*da+(m_e*b_e/6)*db+((a_e^2+b_e^2)/12+l_e^2)*dm+(2*m_e*l_e)*dl;
J_e = (m_e*(a_e^2+b_e^2))/12+m_e*l_e^2;
tau_e = J_e/B_e;
dtau = tau_e*(dJ/J_e+dB/B_e);

```

ผลที่ได้คือค่า k ที่มีค่าเท่ากับ $2.7845 \pm 1.5705 \text{ [s}^{-1}\text{]}$

พารามิเตอร์	ค่าของพารามิเตอร์	หน่วย
ω^*	60 ± 2.5	rpm
k	0.3591 ± 0.2026	s

```

N = 11;
w_0 = 60+2.5*linspace(-1,1,N);
tau = 0.3591+0.2026*linspace(-1,1,N);

```


เราจะสังเกตได้ว่า พารามิเตอร์ที่ไม่แน่นอนนั้นถูกลดจำนวนจาก **6** ตัวเหลือแค่ **2** ตัว ทำให้จำนวนครั้งในการจำลองลดลงเหลือ **121** ครั้ง หากการจำลองหนึ่งครั้งต้องใช้เวลา **0.1 [s]** เดิมที่เราต้องใช้เวลา **49** ชั่วโมงในการจำลอง แต่การลดจำนวนตัวแปรทำให้การจำลองลดเวลาเหลือแค่ **12** วินาที

```

N = 11;
w_e = 60;
w_0 = 60+2.5*linspace(-1,1,N);
tau_e = 0.3591;
tau = 0.3591+0.2026*linspace(-1,1,N);
% at2percent = @(t,y,w_e)deal(y==0.002*w_e,1,-1);
opt = odeset('Events',@(t,y)at2percent(t,y,w_e));
t_max = 10*tau_e;
tspan = [0 t_max];
T_s = zeros(N,N);
for i = 1:N
    for j = 1:N
        [t,y] = ode45(@(t,y)-y/tau(j),tspan,w_0(i),opt);
        T_s(i,j) = t(end);
    end
end

[T,W] = meshgrid(tau,w_0);
clf
ax = axes;
surf(ax,T,W,T_s)
xlabel('$\tau$', 'Interpreter', 'latex')
ylabel('$w_0$', 'Interpreter', 'latex')
zlabel('$T_s$', 'Interpreter', 'latex')

```



```
T_mean = mean(T_s,'all');
T_max = max(T_s,[],'all');
T_min = min(T_s,[],'all');
```

จากจำลอง 121 ครั้ง ค่าเฉลี่ยที่ 2.2319 [s] ค่าที่มากที่สุดที่ 3.5139 [s] และค่าน้อยที่สุดที่ 0.9661 [s] ซึ่งเราเขียนเป็นความไม่แน่นอนได้ที่ 2.2319 ± 1.2820 [s] สาเหตุที่ความไม่แน่นอนสัมพันธ์อยู่ที่ 57.44 % ก็เพราะว่าความไม่แน่นอนของค่าความถี่มีความไม่แน่นอนสัมพันธ์ที่สูงอยู่แล้ว (50.75%) ดังนั้นผลจากการจำลองเลยมีความไม่แน่นอนที่สูงตามเช่นกัน

```
function [condition,isTerminal,direction] = at2percent(t,y,w_e)
condition = y<=0.002*w_e;
isTerminal = 1;
direction = 1;
end
```

ความน่าจะเป็นและสัญญาณสุ่ม (Probability & Random Signal)

ตอนที่ 2 : ตัวแปรสุ่ม (1/2) (Random Variable)

จะอย่างไรก็ตามการอธิบายความไม่แน่นอนในลักษณะบวกลบนี้มีข้อเสียในเรื่องของการหาแนวโน้มและความสัมพันธ์เนื่องจากการระบุความไม่แน่นอนแบบบวกลบไม่ได้ให้ข้อมูลการแจกแจงของค่ามาแต่อย่างใด ถึงแม้ค่าจะมีช่วงที่กำหนดมา แต่ค่าเฉลี่ยจริงนั้นอาจจะไม่ได้อยู่ที่กึ่งกลางของช่วงก็เป็นได้ อีกทั้งความแปรปรวนของค่าอาจจะมีมากหรือน้อยที่แตกต่างกันก็เป็นได้ ดังนั้น ในหลายครั้ง เราจะใช้ความน่าจะเป็น (probability) ในการอธิบายค่าที่เป็นไปได้ของตัวแปร

ตัวแปรที่มีความไม่แน่นอนจะถูกเรียกว่า ตัวแปรสุ่ม (random variable) ซึ่ง เราสามารถอธิบายค่าที่เป็นไปได้ของตัวแปรสุ่มนี้ผ่านความน่าจะเป็น (probability) ซึ่งตัวแปรนี้สามารถมีค่าเป็นได้ 2 ประเภทหลัก

ตัวแปรสุ่มแบบไม่ต่อเนื่อง (discrete random variable)

ประเภทแรกคือตัวแปรสุ่มแบบไม่ต่อเนื่อง (discrete random variable) ซึ่งเป็นตัวแปรที่มีค่าที่เป็นไปได้อยู่ในเซตที่นับได้ ยกตัวอย่างการโยนเหรียญหัวก้อย หากเรากำหนดให้ X เป็นตัวแปรสุ่มที่บ่งบอกว่าเหรียญเป็นหัวหรือเป็นก้อย โดยกำหนดให้ เมื่อ $X = 1$ เป็นเหตุการณ์ที่เหรียญออกเป็นหัว ส่วน $X = 0$ เป็นเหตุการณ์ที่เหรียญออกเป็นก้อย เราจะสามารถเขียนความน่าจะเป็น $P(\cdot)$ ได้ดังต่อไปนี้

$$\begin{aligned}P(X = 1) &= 0.5 \\P(X = 0) &= 0.5\end{aligned}$$

สมการการทั้งสองอธิบายถึงความน่าจะเป็นที่เหรียญจะออกหัวหรือก้อยนั้นเป็น 0.5 ทั้งคู่ (50%)

ความน่าจะเป็นนั้นจะเอาไว้ใช้อธิบายเหตุการณ์ (event) เสมอ ในการอธิบายอย่างเป็นทางการ เราจำเป็นต้องแปลความหมายของเหตุการณ์ให้อยู่ในรูปของสมการหรือสมการ ยกตัวอย่างเช่นการทอยลูกเต๋าด้าน หากต้องการหาความน่าจะเป็นที่ลูกเต๋าดูออกด้านที่มีค่าน้อยกว่า 4 เราต้องกำหนดให้ X เป็นค่าของด้านลูกเต๋าดูออก และเหตุการณ์ที่ลูกเต๋าดูออกด้านที่มีค่าน้อยกว่า 4 จะสามารถถูกเขียนเป็นสมการได้คือ $X < 4$ ดังนั้น ความน่าจะเป็นสามารถเขียนได้เป็นสมการต่อไปนี้

$$P(X < 4) = 0.5$$

เราจะไม่เขียนว่า $P(X)$ เนื่องจาก X ไม่ใช่เหตุการณ์


ตัวอย่างที่ 1 : การทอยลูกเต๋าด้าน

กำหนดให้ลูกเต๋าด้านมีความน่าจะเป็นที่เท่ากันที่จะออกด้านใดด้านหนึ่ง ดังนั้น เราสามารถเขียนความสัมพันธ์ของความน่าจะเป็นได้ดังต่อไปนี้

$$P(X = x) = \frac{1}{6} \quad \text{โดยที่ } x \in \{1, 2, 3, 4, 5, 6\}$$


เราสามารถกราฟความสัมพันธ์ระหว่างค่าของ X และความน่าจะเป็นได้ดังต่อไปนี้

```
clf;
ax = axes;
grid(ax, 'on')
hold(ax, 'on')
x = 1:6;
stem(ax, x, (1/6)*ones(size(x)), 'b')
axis(ax, [-1 8 -0.1 0.5])
xlabel('$x$', 'Interpreter', 'latex')
ylabel('$\mathrm{P}(X=x)$', 'Interpreter', 'latex')
```

การแจกแจงที่ความน่าจะเป็นของทุกเหตุการณ์เท่ากันถูกเรียกว่า การแจกแจงแบบยูนิฟอร์ม (**uniform distribution**) ซึ่งเราสามารถเขียนเป็นโปรแกรมสุ่มโดยใช้ฟังก์ชัน **randi** ได้ดังต่อไปนี้

```
imax = 6;
imin = 1;
sz = [1 10000]; % one row 100 columns
X = randi(imax-imin+1,sz)+imin-1;
clf
ax = axes;
histogram(ax,X)
xlabel('$X=x$', 'Interpreter', "latex")
ylabel('Number of samples')
```



หากโจทย์เปลี่ยนเป็นการทอยลูกเต๋า 2 อันและนับผลรวมจากแต้มของหน้าลูกเต๋าทิ้งสอง เราจะได้ความน่าจะเป็นของแต่ละผลรวมดังต่อไปนี้

$$P(X = 2) = P(X = 12) = \frac{1}{36}$$

$$P(X = 3) = P(X = 11) = \frac{2}{36}$$

$$P(X = 4) = P(X = 10) = \frac{3}{36}$$


$$P(X = 5) = P(X = 9) = \frac{4}{36}$$

$$P(X = 6) = P(X = 8) = \frac{5}{36}$$

$$P(X = 7) = \frac{6}{36}$$

โดยที่ X คือผลรวมของหน้าลูกเต๋าทิ้งออก ซึ่งสามารถกราฟความสัมพันธ์ได้ดังต่อไปนี้

```
clf;
ax = axes;
grid(ax, 'on')
hold(ax, 'on')
x = 2:12;
stem(ax, x, (6-abs(x-7))/36, 'b')
axis(ax, [0 14 -0.05 0.3])
xlabel('$x$', 'Interpreter', "latex")
ylabel('$\mathrm{P}(X=x)$', 'Interpreter', "latex")
```



ในบ้อยครั้ง เหตุการณ์อาจจะมีจำนวนมากซึ่งการเขียนสมการเป็นทีละเหตุการณ์อาจไม่ใช่วิธีที่สะดวกที่สุด เราสามารถใช้ฟังก์ชันในการอธิบายการแจกแจงของความน่าจะเป็น หรือ ฟังก์ชันการแจกแจงความน่าจะเป็น $f_X(\cdot)$ (probability density function/ pdf) สำหรับตัวอย่างการทอยลูกเต๋าสองอัน เราสามารถเขียนฟังก์ชันการแจกแจงความน่าจะเป็นได้ดังต่อไปนี้

$$f_X(x) = (x-1) \cdot \theta(x-2) - 2(x-7) \cdot \theta(x-7) + (x-13) \cdot \theta(x-13)$$

โดยที่ x คือค่าของผลรวมหน้าลูกเต๋าคู่ (จำนวนเต็ม)


ไม่ว่าความน่าจะเป็นจะมีการแจกแจงอย่างไร เราสามารถเขียนความน่าจะเป็นของแต่ละจำนวนเต็มให้อยู่ในรูปของเวกเตอร์ที่มีจำนวนจำกัดได้ โดยการกำหนดตัวแปรที่มีจำนวนจำกัดและใช้ผ่านฟังก์ชันเช่น

$$f_X(x) = \frac{6 - |x-7|}{36} \text{ โดยที่ } x \in \{2, 3, \dots, 12\}$$

ถ้าหากเราเขียนความน่าจะเป็นในรูปแบบที่จำกัดได้ เราก็สามารถเขียนโปรแกรมในการสุ่มตามการแจกแจงใดๆได้ ซึ่งเราจะใช้ฟังก์ชัน **randsample** (จำเป็นต้องใช้ **Statistics & Machine Learning Toolbox**) ได้ดังต่อไปนี้

```
x = 2:12;
pdf = (6-abs(x-7))/36;
sz = 10000;
X = randsample(x,sz,true,pdf);

clf
ax = axes;
histogram(ax,X)
xlabel('$X=x$', 'Interpreter', 'latex')
ylabel('Number of samples')
```



หนึ่งในคุณสมบัติของฟังก์ชันการแจกแจงความน่าจะเป็นสำหรับตัวแปรที่ไม่ต่อเนื่องคือผลรวมของความน่าจะเป็นของทุกเหตุการณ์ต้องเท่ากับ **1** หรือเขียนเป็นสมการได้ดังต่อไปนี้

$$\sum_x f_X(x) = 1$$

อีกหนึ่งในคุณสมบัติของฟังก์ชันการแจกแจงคือฟังก์ชันต้องไม่เป็นลบ

$$0 \leq f_X(x) \leq 1$$

ความน่าจะเป็นและสัญญาณสุ่ม (Probability & Random Signal)

ตอนที่ 3 : ตัวแปรสุ่ม (2/2) (Random Variable)

ตัวแปรสุ่มแบบต่อเนื่อง (continuous random variable)

ตัวแปรสุ่มประเภทที่สองคือตัวแปรสุ่มแบบต่อเนื่อง (continuous random variable) ซึ่งเป็นตัวแปรที่มีค่าที่เป็นไปได้อยู่ในเซตที่นับไม่ได้ ยกตัวอย่างเช่น เวลาที่รถไฟจะมาถึงสถานี หรือ ความยาวของเส้นผ่านศูนย์กลางของเพลาคูที่ถูกกลึง ค่าเหล่านี้ล้วนมีค่าที่เป็นไปได้ที่ต่อเนื่อง (continuous)

หากเรากำหนดให้ระยะเวลาที่รถไฟจะมาถึงสถานีเป็น X ถึงแม้ว่ารถไฟจะถูกจัดตารางมาให้ถึงทุกๆ 10 นาที ความน่าจะเป็นที่ระยะเวลานั้นจะเท่ากับ 10 นาที จะมีค่าเท่ากับ 0 ในทางทฤษฎี เหตุการณ์ที่ระยะเวลาจะเท่ากับ 10 นาที มีแค่ครั้งเดียวเทียบกับเหตุการณ์อื่นๆที่ระยะเวลาเท่ากับค่าอื่นเช่น 10.1, 10.01, 10.001, 10.0001, 10.00000001, 9.9, 9.99, 9.9999 เราสามารถเขียนเหตุการณ์ที่เกิดขึ้นนั้นได้เป็นจำนวนครั้งไม่ถ้วนเนื่องจากค่าของตัวแปรเป็นค่าต่อเนื่อง ดังนั้น ความน่าจะเป็นของเหตุการณ์ที่ตัวแปรสุ่มมีค่าเท่ากับค่าคงที่ค่าหนึ่งนั้นจะเป็น 0 เสมอ

$$P(X = 0) = 0$$

หรือกล่าวได้อีกอย่างคือ เราไม่ควรใช้สมการในการอธิบายเหตุการณ์สำหรับตัวแปรสุ่มแบบต่อเนื่อง

ตัวอย่างที่ 1 : การกลึงเพลาคู

โรงงานมีเครื่องกลึงอยู่ 2 เครื่อง ซึ่งแต่ละเครื่องถูกตั้งค่าไว้สำหรับกลึงเพลาคูให้มีเส้นผ่านศูนย์กลาง ขนาด 4 [cm]

กำหนดให้ D_A และ D_B เป็นขนาดของเส้นผ่านศูนย์กลางของเพลาคูที่สร้างโดยเครื่องกลึง A และเครื่องกลึง B ตามลำดับ

หากเรากำหนดความเผื่อ (tolerance) ในการผลิตไว้ที่ 0.01 [cm] เราสามารถเปรียบเทียบสมรรถนะของเครื่องกลึงแต่ละเครื่องได้ดังนี้

$$P(|D_A - 4| \leq 0.01) = 0.6827$$

$$P(|D_B - 4| \leq 0.01) = 0.9545$$

จากตัวอย่างที่กำหนด ทำให้เราสรุปได้ว่า เครื่องกลึง B มีสมรรถนะที่ดีกว่า (จาก หนึ่งร้อยชิ้นที่ผลิต เพลาคูจากเครื่องกลึง A จำนวน 68 ชิ้น ผ่านตามเกณฑ์ที่กำหนด แต่เพลาคูจากเครื่องกลึง B จำนวน 95 ชิ้นผ่านตามเกณฑ์ที่กำหนด)

การแจกแจงของความน่าจะเป็น (probability distribution)

เหตุการณ์ที่เกี่ยวข้องกับตัวแปรสุ่มแบบต่อเนื่องจะถูกอธิบายโดยใช้สมการ หรือ ช่วงที่เป็นไปได้ของค่า เช่น

$$P(X \leq 1) , P(-0.3 \leq X \leq 0.1) , P(|x - 2.5| \leq 0.1)$$

เช่นเดียวตัวแปรสุ่มแบบไม่ต่อเนื่อง การแจกแจงของความน่าจะเป็นของตัวแปรต่อเนื่องสามารถเขียนอยู่ในรูปของฟังก์ชันได้ ซึ่งต้องมีความสัมพันธ์ดังต่อไปนี้

$$\int_{-\infty}^{\infty} \{f_X(x)\} dx = 1$$
$$0 \leq f_X(x) \leq 1, \quad 0 \leq x$$

เรากำหนดให้ความสัมพันธ์ระหว่าง ความน่าจะเป็น และการแจกแจงของความน่าจะเป็นดังต่อไปนี้

$$P(X \leq k) = \int_{-\infty}^k \{f_X(x)\} dx$$

ความน่าจะเป็นที่ตัวแปรสุ่มจะมีค่าน้อยกว่าหรือเท่ากับ k มีค่าเท่ากับการหาพื้นที่ใต้กราฟของฟังก์ชันการแจกแจงความน่าจะเป็นจากลบอนันต์ถึงค่า k

จากความสัมพันธ์ดังกล่าว เราสามารถคำนวณหาความน่าจะเป็นของเหตุการณ์ที่ถูกเขียนในรูปของสมการดังต่อไปนี้

$$\begin{aligned} P(X \geq k) &= 1 - P(X \leq k) = 1 - \int_{-\infty}^k \{f_X(x)\} dx \\ &= \int_{-\infty}^{\infty} \{f_X(x)\} dx - \int_{-\infty}^k \{f_X(x)\} dx \\ &= \int_k^{\infty} \{f_X(x)\} dx \end{aligned}$$

$$\begin{aligned} P(|X - \mu| \leq k) &= P(\mu - k \leq X \leq \mu + k) = 1 - P(X \leq \mu - k) - P(X \geq \mu + k) \\ &= \int_{-\infty}^{\infty} \{f_X(x)\} dx - \int_{-\infty}^{\mu-k} \{f_X(x)\} dx - \int_{\mu+k}^{\infty} \{f_X(x)\} dx \\ &= \int_{\mu-k}^{\mu+k} \{f_X(x)\} dx \end{aligned}$$

ดังนั้น เราสามารถอธิบายการแจกแจงโดยใช้ฟังก์ชันได้ครบโดเมนที่ฟังก์ชันนั้นมีคุณสมบัติต่อไปนี้

$$\begin{aligned} \int_{-\infty}^{\infty} \{f_X(x)\} dx &= 1 \\ f_X(x) &\geq 0 \quad \forall x \end{aligned}$$

การแจกแจงแบบยูนิฟอร์ม (Uniform Distribution)


ในกรณีที่เหตุการณ์นั้นเกิดขึ้นอยู่ในช่วงที่จำกัด

$$X \in [x_{\min}, x_{\max}]$$

และมีการแจกแจงความน่าจะเป็นอย่างเท่ากันทุกเหตุการณ์ เราสามารถเขียนฟังก์ชันการแจกแจงความน่าจะเป็นได้ดังต่อไปนี้

$$f_X(x) = \frac{\theta(x - x_{\min}) - \theta(x - x_{\max})}{x_{\max} - x_{\min}}$$

```
clf
ax = axes;
hold(ax, 'on')
grid(ax, 'on')
x_max = 6;
x_min = 2;
x = 0:0.01:8;
plot(ax, x, ((x >= x_min) - (x >= x_max)) / (x_max - x_min))
xlabel('$x$', 'Interpreter', 'latex');
ylabel('$f_X(x)$', 'Interpreter', 'latex')
axis(ax, [0 8 -0.05 0.3])
```



เราสามารถนำแนวคิดนี้ไปเขียนเป็นโปรแกรมที่ใช้ในการสุ่มตัวเลขที่เป็นค่าต่อเนื่องในช่วงได้ดังต่อไปนี้

```
x_max = 6;
x_min = 2;
sz = [1,100];
X = (x_max-x_min)*rand(sz)+x_min;
```

การสุ่มแบบดังกล่าวเหมาะสำหรับตัวแปรสุ่มที่เราไม่ทราบค่าแน่ชัดแต่เราสามารถหาช่วงของค่ามันได้และทุกค่าที่อยู่ในช่วงมีโอกาสที่จะเป็นได้เท่าๆกัน

การแจกแจงแบบปกติ (Normal (Gaussian) Distribution)

ในหลายครั้ง การแจกแจงของความน่าจะเป็นไม่ได้มีค่าเท่ากันหมดในทั้งช่วง การแจกแจงของความน่าจะเป็นนั้นอาจจะเกาะกลุ่มใกล้ค่าหนึ่งมากกว่าค่าอื่นๆในช่วง หนึ่งใน การแจกแจงความน่าจะเป็นที่พบเห็นบ่อยในการวิเคราะห์เชิงสถิติและงานวิจัยได้แก่การแจกแจงแบบปกติ หรือ การแจกแจงแบบเกาส์เซียน (normal/Gaussian distribution) ซึ่งสามารถเขียนเป็นฟังก์ชันได้ดังต่อไปนี้

$$f_X(x) = \frac{1}{\sqrt{2\pi\sigma_X^2}} e^{-\frac{1}{2}\left(\frac{x-\mu_X}{\sigma_X}\right)^2}$$

โดยที่


μ_X และ σ_X เป็นพารามิเตอร์ของฟังก์ชันนี้ (ซึ่งมีบทบาทเกี่ยวข้องกับค่าคาดหวังและค่าแปรปรวน)

```
clf
ax = axes;
hold(ax, 'on')
```

```

grid(ax,'on')
mu = 4;
sigma_sqr = [0.2 0.5 1 5];
sigma = sqrt(sigma_sqr);
lab = cell(1,numel(sigma));
x = (-4*max(sigma):0.01:4*max(sigma))+mu;
for i = 1:numel(sigma)
    s = sigma(i);
    plot(ax,x,exp(-0.5*((x-mu)/s).^2)/sqrt(2*pi*s^2))
    xlabel('$x$', 'Interpreter','latex');
    ylabel('$f_X(x)$', 'Interpreter','latex')
    axis(ax,[min(x) max(x) -0.05 1]);
    lab{i} = sprintf('$\sigma^2 = %.1f$',sigma_sqr(i));
end
legend(lab,'Interpreter','latex')

```




ค่า σ_X ของฟังก์ชันบ่งบอกถึงความแปรปรวนของค่า X ในบริเวณรอบค่า μ_X ซึ่งค่าของ σ_X มีค่าน้อย ความน่าจะเป็นที่ X อยู่บริเวณรอบๆ μ_X จะยิ่งมีมากขึ้น การแจกแจงความน่าจะเป็นแบบดังกล่าวนี้อาจมีประโยชน์ถ้าเราทราบถึงค่าคาดหวังและค่าแปรปรวนของตัวแปรสุ่ม ซึ่งเราสามารถนำมาเขียนเป็นโปรแกรมในการสุ่มได้ดังนี้

```

sigma_sqr = 0.1;
mu = 4;
X = sqrt(sigma_sqr)*randn([1,100000])+mu;
clf;
ax = axes;
hold(ax,'on')
histogram(ax,X)

```

การแจกแจงของความน่าจะเป็นแบบปกติเป็นการแจกแจงที่ได้รับความนิยม เนื่องจากมีความเกี่ยวข้องกับ ทฤษฎี **Central Limit Theorem** และพฤติกรรมหรือพลวัตต่างๆ ตามธรรมชาติล้วนแต่ให้ผลลัพธ์ทางสถิติที่มีลักษณะเป็นระฆังคว่ำหรือการแจกแจงแบบปกตินั่นเอง

การแจกแจงแบบปกติด้วยลอการิทึม (Log-Normal Distribution)

สมมติว่าเรากำหนดอัตราเร็วเชิงเส้น (linear speed) ของหุ่นยนต์ที่ค่า V แต่ในโลกความจริง อัตราเร็วของหุ่นยนต์นั้นมีความไม่แน่นอนอยู่ เราสามารถจำลองความน่าจะเป็นของอัตราเร็วด้วยการเลือกลักษณะการแจกแจง อย่างไรก็ตาม ค่าของอัตราเร็วนั้นมีค่าเป็นที่ยอมรับมากกว่าหรือเท่ากับ 0 ดังนั้นเราไม่สามารถใช้การแจกแจงแบบปกติได้


แต่ถ้าเรามาความเร็วเป็นค่าที่โคจรใกล้ค่าต่อไปนี้

$$V = e^W$$

เราสามารถให้ค่าของเลขยกกำลัง W มีการแจกแจงแบบปกติ ผลลัพธ์ที่ได้คือความเร็วที่มีการกระจายตัวแบบปกติด้วยลอการิทึม (log-normal distribution) ซึ่งมีฟังก์ชันการแจกแจงของความน่าจะเป็นในรูปแบบดังต่อไปนี้

$$f_V(v) = \frac{1}{v \cdot \sigma_V \sqrt{2\pi}} e^{-\frac{1}{2} \left(\frac{\ln(v) - \mu_V}{\sigma_V} \right)^2}$$

```
mu = log(1);
sigma = 0.4;
X = lognrnd(mu,sigma,[1,100000]);
clf;
ax = axes;
hold(ax,'on')
histogram(ax,X)
```



ความน่าจะเป็นและสัญญาณสุ่ม (Probability & Random Signal)

ตอนที่ 4 : ค่าคาดหวัง ค่าแปรปรวน และ ค่าเบี่ยงเบนมาตรฐาน (Expected Value, Variance, & Standard Deviation)

ค่าคาดหวัง (Expected Value)

หนึ่งในคุณลักษณะของการแจกแจงของความน่าจะเป็นคือค่าคาดหวัง ค่าคาดหวังนี้ถูกใช้ในการประมาณเหตุการณ์ที่น่าจะเป็นไปได้มากที่สุดโดยอ้างอิงจากฟังก์ชันการแจกแจง

หากตัวแปรสุ่ม X เป็นแบบไม่ต่อเนื่อง เราสามารถคำนวณค่าคาดหวัง $E\{X\}$ หรือ μ_X ได้ดังต่อไปนี้

$$E\{X\} = \mu_X = \sum_{\text{all } x} x \cdot f_X(x)$$

ยกตัวอย่างเช่น ค่าคาดหวังของผลรวมของหน้าของลูกเต๋า 2 อันที่ถูกทอดสามารถคำนวณได้ดังต่อไปนี้

$$\begin{aligned}\mu_X = E\{X\} &= \sum_{x=2}^{12} x \cdot \left(\frac{6 - |x - 7|}{36}\right) \\ &= \sum_{x=2}^7 x \cdot \left(\frac{6 - (7 - x)}{36}\right) + \sum_{x=8}^{12} x \cdot \left(\frac{6 - (x - 7)}{36}\right) \\ &= \sum_{x=2}^7 x \cdot \left(\frac{x - 1}{36}\right) + \sum_{x=8}^{12} x \cdot \left(\frac{13 - x}{36}\right) = 7\end{aligned}$$

```
x2_7 = 2:7;  
x8_12 = 8:12;  
mu_X = sum(x2_7.*(x2_7-1)/36)+sum(x8_12.*(13-x8_12)/36);
```

หากตัวแปรสุ่ม X เป็นแบบต่อเนื่อง เราสามารถคำนวณค่าคาดหวัง $E\{X\}$ หรือ μ_X ได้ดังต่อไปนี้ในรูปแบบของสมการปริพันธ์ดังต่อไปนี้

$$\mu_X = E\{X\} = \int_{-\infty}^{\infty} \{x \cdot f_X(x)\} dx$$

จากนิยามของค่าคาดหวัง คุณสมบัติของค่าคาดหวังมีดังต่อไปนี้

กำหนดให้ k เป็นค่าคงที่ ดังนั้นฟังก์ชันการแจกแจงของค่าคงที่จะอยู่ในรูปของฟังก์ชันแรงดล (impulse function) ดังนี้

$$f_X(x) = \delta(x - k)$$

ดังนั้นเราสามารถหาค่าคาดหวังของค่าคงที่ได้ดังนี้

$$E\{k\} = \int_{-\infty}^{\infty} \{x \cdot \delta(x - k)\} dx = \int_{-\infty}^{\infty} \{(x + k) \cdot \delta(x)\} dx = k$$

สาเหตุที่เราสามารถหาปริพันธ์เป็นเพราะคุณสมบัติของฟังก์ชันแรงดลดังต่อไปนี้

$$\int_{-\infty}^{\infty} \{f(x) \cdot \delta(x)\} dx = f(0)$$

นอกจากนี้เราสามารถคำนวณหาค่าคาดหวังของตัวแปรสุ่มที่ถูกคูณด้วยค่าคงที่ $Y = k \cdot X$

$$\begin{aligned}
E\{Y\} &= E\{k \cdot X\} \\
&= \int_{-\infty}^{\infty} \{(k \cdot x) \cdot f_X(x)\} dx = k \cdot \int_{-\infty}^{\infty} \{x \cdot f_X(x)\} dx \\
&= k \cdot E\{X\}
\end{aligned}$$

หลักการเดียวกันนี้สามารถใช้ในการพิสูจน์หาค่าคาดหวังของผลบวกของหลายฟังก์ชันได้ดังนี้

$$\begin{aligned}
Y &= g(X) + h(X) \\
E\{Y\} &= E\{g(X) + h(X)\} = \int_{-\infty}^{\infty} \{(g(x) + h(x)) \cdot f_X(x)\} dx \\
&= \int_{-\infty}^{\infty} \{g(x) \cdot f_X(x)\} dx + \int_{-\infty}^{\infty} \{h(x) \cdot f_X(x)\} dx \\
&= E\{g(X)\} + E\{h(X)\}
\end{aligned}$$

ดังนั้นเราสามารถสรุปเป็นสมบัติได้ดังนี้

ตัวแปรสุ่ม	ค่าคาดหวัง
k	k
$k \cdot X$	$k \cdot E\{X\}$
$g(X) + h(X)$	$E\{g(X)\} + E\{h(X)\}$

ค่าแปรปรวน (Variance)

อีกคุณลักษณะหนึ่งของการแจกแจงของความน่าจะเป็นคือค่าแปรปรวนซึ่งบอกถึงการกระจายตัวของค่าที่ตัวแปรสามารถเป็นได้ ยิ่งค่าแปรปรวนมาก การแจกแจงความน่าจะเป็นก็จะกว้างตามไปด้วย ที่สำคัญที่สุดคือค่าแปรปรวนนั้นจะต้องมากกว่าหรือเท่ากับศูนย์เสมอ

หากกำหนดให้ X เป็นตัวแปรสุ่ม เราสามารถคำนวณหาความแปรปรวน $\text{Var}\{X\}$ หรือ σ_X^2 ได้ดังต่อไปนี้

$$\begin{aligned}
\sigma_X^2 &= \text{Var}\{X\} = E\{(X - \mu_X)^2\} \\
&= E\{X^2 - 2X\mu_X + \mu_X^2\} \\
&= E\{X^2\} - 2\mu_X \cdot E\{X\} + E\{\mu_X^2\} \\
&= E\{X^2\} - \mu_X^2
\end{aligned}$$

ยกตัวอย่างเช่น ค่าแปรปรวนของผลรวมของหน้าของลูกเต๋า 2 อันที่ถูกทอดสามารถคำนวณได้ดังต่อไปนี้

$$\begin{aligned}
\sigma_X^2 &= \text{Var}\{X\} = E\{X^2\} - \mu_X^2 \\
&= \sum_{x=2}^{12} x^2 \cdot \left(\frac{6 - |x - 7|}{36}\right) - 7^2 \\
&= \sum_{x=2}^7 x^2 \cdot \left(\frac{6 - (7 - x)}{36}\right) + \sum_{x=8}^{12} x^2 \cdot \left(\frac{6 - (x - 7)}{36}\right) - 49 \\
&= \sum_{x=2}^7 x^2 \cdot \left(\frac{x - 1}{36}\right) + \sum_{x=8}^{12} x^2 \cdot \left(\frac{13 - x}{36}\right) - 49 = \frac{35}{6}
\end{aligned}$$

x2_7 = 2:7;
x8_12 = 8:12;

$$\mu_X = \text{sum}(x2_7.^2 \cdot (x2_7-1)/36) + \text{sum}(x8_12.^2 \cdot (13-x8_12)/36) - 49;$$

จากนิยามของค่าแปรปรวนที่กล่าวมา เราสามารถหาสมบัติของค่าแปรปรวนได้ดังต่อไปนี้

กำหนดให้ค่า k เป็นค่าคงที่ ค่าแปรปรวนนั้นจะเท่ากับศูนย์เนื่องจากค่าคงที่เป็นค่าที่ทราบอยู่แล้วและไม่แปรปรวน ซึ่งสามารถพิสูจน์ได้ดังนี้

$$\sigma_X^2 = \text{Var}\{k\} = E\{k^2\} - k^2 = k^2 - k^2 = 0$$

อีกสมบัติหนึ่งที่เราสามารถพิสูจน์จากนิยามของค่าคาดหวังและค่าแปรปรวนคือค่าแปรปรวนของตัวแปรสุ่มที่ถูกคูณด้วยค่าคงที่ ซึ่งสามารถพิสูจน์ได้ดังต่อไปนี้

$$\begin{aligned}\sigma_X^2 &= \text{Var}\{k \cdot X\} = E\{(k \cdot X)^2\} - (k \cdot \mu_X)^2 \\ &= E\{k^2 \cdot X^2\} - k^2 \cdot \mu_X^2 = k^2 \cdot E\{X^2\} - k^2 \cdot \mu_X^2 \\ &= k^2 \cdot (E\{X^2\} - \mu_X^2) = k^2 \cdot \text{Var}\{X\}\end{aligned}$$

ความน่าจะเป็นและสัญญาณสุ่ม (Probability & Random Signal)

ตอนที่ 5 : ตัวแปรสุ่มหลายตัวแปร (Multiple Random Variables)

ความน่าจะเป็นร่วม (Joint Probability)

เราใช้ตัวแปรสุ่มหนึ่งตัวในการอธิบายเหตุการณ์หนึ่งเหตุการณ์ในกรณีต่างๆ แต่เราสามารถอธิบายเหตุการณ์หลายๆเหตุการณ์ที่เกิดขึ้นพร้อมกันโดยใช้ตัวแปรสุ่มมากกว่าหนึ่งตัว เช่น เหตุการณ์ที่ฟ้าครึ้มและฝนตกพร้อมกัน หรือ เหตุการณ์ที่ไพ่ใบแรกเป็น King และไพ่ใบที่สองเป็น Queen เราสามารถใช้ตรรกศาสตร์ในการอธิบายเหตุการณ์ที่เกิดขึ้นพร้อมกัน หากกำหนดให้เหตุการณ์แรกเป็น E_1 และเหตุการณ์ที่สองเป็น E_2 เราจะเขียนเหตุการณ์และความน่าจะเป็นที่ทั้งสองเหตุการณ์เกิดขึ้นพร้อมกันได้ดังต่อไปนี้

$$E = E_1 \wedge E_2$$
$$P(E) = P(E_1 \wedge E_2)$$

เราเรียกความน่าจะเป็นนี้ว่าความน่าจะเป็นร่วม (joint probability) ซึ่งความสัมพันธ์ของความน่าจะเป็นสามารถสรุปเป็นตารางได้ดังต่อไปนี้

เหตุการณ์		E_1	$\neg E_1$	$E_1 \vee \neg E_1 = \text{True}$
—	+	—	—	—
E_2		$P(E_1 \wedge E_2)$	$P(\neg E_1 \wedge E_2)$	$P(E_2) = P(E_1 \wedge E_2) + P(\neg E_1 \wedge E_2)$
$\neg E_2$		$P(E_1 \wedge \neg E_2)$	$P(\neg E_1 \wedge \neg E_2)$	$P(\neg E_2) = P(E_1 \wedge \neg E_2) + P(\neg E_1 \wedge \neg E_2)$
$E_2 \vee \neg E_2 = \text{True}$		$P(E_1) = P(E_1 \wedge E_2) + P(E_1 \wedge \neg E_2)$	$P(\neg E_1) = P(\neg E_1 \wedge E_2) + P(\neg E_1 \wedge \neg E_2)$	$P(E_1) + P(\neg E_1) = P(E_2) + P(\neg E_2) = 1$

ความน่าจะเป็นแบบมีเงื่อนไข (Conditional Probability)

ในหลายครั้ง เราสามารถที่จะสังเกตเหตุการณ์ (observe) เพื่อใช้ในการคาดเดาว่าอีกเหตุการณ์หนึ่งจะเกิดขึ้นหรือไม่ เช่น ความน่าจะเป็นที่มีคนมาเยี่ยมบ้านเมื่อเราได้ยินเสียงสุนัขที่บ้านเห่า หรือ ความน่าจะเป็นที่อาชญากรรมจะเกิดขึ้น โดยที่เราเห็นโคนันกับแก๊งค์นักสืบชาวชนในบริเวณนั้น

ความน่าจะเป็นแบบดังกล่าวถูกเรียกว่า ความน่าจะเป็นแบบมีเงื่อนไข (conditional probability)

ความน่าจะเป็นแบบเงื่อนไขนี้สามารถถูกคำนวณได้จากความสัมพันธ์ดังต่อไปนี้

$$P(E_1|E_2) = \frac{P(E_1 \wedge E_2)}{P(E_2)}$$

โดยที่

$P(E_1|E_2)$ คือความน่าจะเป็นที่เหตุการณ์ E_1 เกิดขึ้นโดยกำหนดให้ เหตุการณ์ E_2 เกิดขึ้น

$P(E_1 \wedge E_2)$ คือความน่าจะเป็นร่วมเหตุการณ์ E_1 เกิดขึ้นพร้อมกับ เหตุการณ์ E_2

จากตารางและนิยามของความน่าจะเป็นแบบเงื่อนไข เราสามารถหาความสัมพันธ์ของความน่าจะเป็นดังกล่าวได้

$$P(E_1) = P(E_1 \wedge E_2) + P(E_1 \wedge \neg E_2) = P(E_1|E_2) \cdot P(E_2) + P(E_1|\neg E_2) \cdot P(\neg E_2)$$

นอกจากนี้ เราสามารถหาความสัมพันธ์ของความน่าจะเป็นแบบเงื่อนไข ได้ในรูปของทฤษฎีของ (Bayes' theorem) ได้ดังต่อไปนี้

$$P(E_1|E_2) = \frac{P(E_2|E_1) \cdot P(E_1)}{P(E_2)} = \frac{P(E_2|E_1) \cdot P(E_1)}{P(E_2|E_1) \cdot P(E_1) + P(E_2|\neg E_1) \cdot P(\neg E_1)}$$

ตัวอย่างที่ 1 : Am I being robbed ?

ณ ธนาคารเล็กๆแห่งหนึ่ง นายธนาคารได้จ้างรปภ.คนใหม่ที่มีประสิทธิภาพสูง ถ้าไม่เกิดเหตุการณ์ปล้นในธนาคารภายในหนึ่งกะ นายรปภ.คนดังกล่าวจะมีโอกาสหลับที่ 1% ($S = 0$ คือรปภ. ไม่หลับ $S = 1$ คือรปภ. หลับ) จะอย่างไรก็ตาม นายธนาคารเป็นคนที่รอบคอบ เขาได้วิเคราะห์ข้อมูลจากธนาคารสาขาอื่นๆ ทำให้เขาทราบว่าความน่าจะเป็นที่ธนาคารจะโดนปล้นต่อหนึ่งกะคือ 10% ($R = 0$ คือไม่โดนปล้น $R = 1$ คือโดนปล้น)

ในรถตู้ที่อยู่นอกถนนถัดไปมีกลุ่มโจรกำลังวางแผนโจรกรรมกับธนาคารแห่งนี้ โจรกลุ่มนี้ตัดสินใจที่จะใช้ลูกดอกยาสลบซึ่งมีผลทำให้คนหลับได้ทันทีเมื่อปืนของฝ่ายโจรบอกกับคนวางแผนที่เขาอาจจะเผลอยิงโดนหัวเข็มขัดหรือสิ่งของอื่นๆ ได้ซึ่งโอกาสในการยิงโดนรปภ.จริงๆคือ 95% กล่าวอีกอย่างคือ มีโอกาส 95% ที่รปภ.จะหลับถ้าเกิดการปล้น

เมื่อนายธนาคารถึงเวลาออกมาตรวจเช็คงาน นายธนาคารเห็นสภาพรปภ.กำลังนั่งหลับอยู่ คำถามคือความน่าจะเป็นที่ธนาคารโดนปล้นอยู่เป็นเท่าไร

คำถามที่ถามมานั้นถามถึงความน่าจะเป็นแบบเงื่อนไขซึ่งสามารถเขียนได้ดังต่อไปนี้

$P(R = 1 | S = 1)$: ความน่าจะเป็นที่ธนาคารกำลังโดนปล้นเมื่อเห็นว่ารปภ. หลับอยู่

เราสามารถใช้ความสัมพันธ์และทฤษฎีของเบย์ในการคำนวณหาความน่าจะเป็นที่ธนาคารกำลังโดนปล้นเมื่อเห็นว่ารปภ. หลับอยู่ได้ดังนี้

$$\begin{aligned} P(R = 1 | S = 1) &= \frac{P(R = 1 \wedge S = 1)}{P(S = 1)} = \frac{P(S = 1 | R = 1) \cdot P(R = 1)}{P(S = 1)} \\ &= \frac{P(S = 1 | R = 1) \cdot P(R = 1)}{P(S = 1 | R = 1) \cdot P(R = 1) + P(S = 1 | R = 0) \cdot (1 - P(R = 1))} \\ &= \frac{0.95 \cdot 0.1}{0.95 \cdot 0.1 + 0.01 \cdot (1 - 0.1)} \approx 0.9135 \end{aligned}$$

$S1R0 = 0.01;$

$R1 = 0.1;$

$S1R1 = 0.95;$

$R1S1 = S1R1 \cdot R1 / (S1R1 \cdot R1 + S1R0 \cdot (1 - R1))$

$R1S1 = 0.9135$

นั่นหมายความว่าคนที่เห็นว่ารปภ. หลับอยู่อาจจะมีโอกาส 91.35% ธนาคารกำลังโดนปล้นอยู่

ตัวแปรที่อิสระต่อกัน (Independent Random Variables)

หากเหตุการณ์ทั้งสองเหตุการณ์นั้นเป็นอิสระต่อกัน (independent) เหตุการณ์หนึ่งจะไม่ส่งผลอะไรให้อีกเหตุการณ์หนึ่งเลย ซึ่งสามารถเขียนเป็นสมการความสัมพันธ์ได้ดังต่อไปนี้

$$P(E_1 | E_2) = P(E_1)$$

จากสมการดังกล่าวและทฤษฎีของเบย์ เราสามารถที่จะคำนวณหาความน่าจะเป็นร่วมของทั้งสองเหตุการณ์ที่เป็นอิสระต่อกันได้ดังนี้

$$P(E_1 \wedge E_2) = P(E_1) \cdot P(E_2)$$

ตัวอย่างที่ 2 : โยนเหรียญ

กำหนดให้เหรียญที่ถูกโยนมีความน่าจะเป็นที่ออกหัวหรือก้อยเท่าๆกัน หากเราโยนเหรียญ 10 ครั้งติดต่อกัน ความน่าจะเป็นจะออกหัวอย่างน้อย 1 ครั้งเป็นเท่าไร

กำหนดให้ X_k เป็นตัวแปรที่บอกถึงผลของการโยนเหรียญครั้งที่ k ($X_k = 0$ เหรียญที่โยนออกก้อย $X_k = 1$ เหรียญที่โยนออกหัว)

เราสามารถหาความน่าจะเป็นของแต่ละการโยนออกเป็นก้อนได้ดังต่อไปนี้

$$P(X_k = 0) = 0.5$$

ความน่าจะเป็นที่ทุกการโยนมีผลออกมาเป็นก้อน $E_{AT} = (X_1 = 0) \wedge (X_2 = 0) \wedge \dots \wedge (X_{10} = 0)$ สามารถเขียนอยู่ในรูปของผลคูณความน่าจะเป็นในการโยนของแต่ละครั้งเนื่องจากว่าการโยนในแต่ละครั้งเป็นอิสระต่อกัน ดังนั้น

$$P(E_{AT}) = P(X_1 = 0) \cdot P(X_2 = 0) \cdot \dots \cdot P(X_{10} = 0) = (0.5)^{10}$$

กำหนดให้ E_H เป็นเหตุการณ์ที่โยนเหรียญทั้งหมด 10 เหรียญและผลออกมาเป็นหัวอย่างน้อย 1 ครั้งนั้นซึ่งเป็นเหตุการณ์ที่ตรงกันข้ามกับเหตุการณ์ที่โยนเหรียญทั้งหมด 10 เหรียญและผลออกมาเป็นก้อยทั้ง 10 ครั้ง

$$P(E_H) = 1 - P(E_{AT}) = 1 - (0.5)^{10} \approx 0.9990$$

ฟังก์ชันการแจกแจงของความน่าจะเป็นร่วม (joint probability distribution function)

เช่นเดียวกับตัวแปรเดี่ยว เราสามารถใช้ฟังก์ชันในการอธิบายการแจกแจงของความน่าจะเป็นร่วมโดยใช้ฟังก์ชันหลายตัวแปร (multi-variable function)

หากเรากำหนดให้ X และ Y เป็นตัวแปรสุ่มแบบไม่ต่อเนื่อง เราสามารถเขียนความสัมพันธ์ของความน่าจะเป็นได้ดังต่อไปนี้

$$P((X = x) \wedge (Y = y)) = f_{XY}(x, y)$$

ซึ่งฟังก์ชันการแจกแจงของตัวแปรสุ่มแบบไม่ต่อเนื่องต้องมีพฤติกรรมดังต่อไปนี้

$$\sum_{\text{for all } y} \sum_{\text{for all } x} f_{XY}(x, y) = 1$$
$$0 \leq f_{XY}(x, y) \leq 1$$

หากเรากำหนดให้ X และ Y เป็นตัวแปรสุ่มแบบต่อเนื่อง เราสามารถเขียนความสัมพันธ์ของความน่าจะเป็นได้ดังต่อไปนี้

$$P((X \leq k) \wedge (Y \leq h)) = \int_{-\infty}^h \int_{-\infty}^k f_{XY}(x, y) \, dx \, dy$$

ซึ่งฟังก์ชันการแจกแจงของตัวแปรสุ่มแบบไม่ต่อเนื่องต้องมีพฤติกรรมดังต่อไปนี้

$$\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f_{XY}(x, y) \, dx \, dy = 1$$
$$f_{XY}(x, y) \geq 0$$

หากตัวแปรทั้งสองตัวเป็นอิสระต่อกัน ฟังก์ชันการแจกแจงสามารถถูกเขียนในรูปของผลคูณได้ดังต่อไปนี้

$$f_{XY}(x, y) = f_{XY}(x) \cdot f_{XY}(y)$$

ความน่าจะเป็นและสัญญาณสุ่ม (Probability & Random Signal)

ตอนที่ 6 : ความสัมพันธ์ระหว่างตัวแปรสุ่มหลายตัว (Relationship between Multiple Random Variables)

ค่าแปรปรวนร่วมเกี่ยว (Covariance)

ค่าของตัวแปรสุ่มสองตัวสามารถแปรปรวนร่วมกันได้ เราเรียกค่านี้ว่าค่าแปรปรวนร่วมเกี่ยว (covariance)

หากเรากำหนดให้ X และ Y เป็นตัวแปรสุ่ม ค่าแปรปรวนร่วมเกี่ยว $\text{Cov}\{X, Y\}$ หรือ σ_{XY} ของตัวแปร X และ Y จะถูกนิยามดังต่อไปนี้

$$\begin{aligned}\sigma_{XY} &= \text{Cov}\{X, Y\} = E\{(X - \mu_X) \cdot (Y - \mu_Y)\} \\ &= E\{X \cdot Y - \mu_X \cdot Y - X \cdot \mu_Y + \mu_X \cdot \mu_Y\} \\ &= E\{X \cdot Y\} - \mu_X \cdot E\{Y\} - \mu_Y \cdot E\{X\} + \mu_X \cdot \mu_Y \\ &= E\{X \cdot Y\} - \mu_X \cdot \mu_Y\end{aligned}$$

ซึ่งความแปรปรวนร่วมเกี่ยวจะมีสมบัติดังต่อไปนี้

$$\begin{aligned}\text{Cov}\{X, Y\} &= \text{Cov}\{Y, X\} \\ |\text{Cov}\{X, Y\}| &\leq \sqrt{\text{Var}\{X\} \cdot \text{Var}\{Y\}}\end{aligned}$$

ค่าแปรปรวนร่วมเกี่ยวนั้นอธิบายถึงความแปรปรวนที่ของตัวแปรนั้นแปรเปลี่ยนไปในทางเดียวกัน

ค่าสหสัมพันธ์ (Correlation)

อีกหนึ่งค่าที่สามารถอธิบายความสัมพันธ์ระหว่างตัวแปรสุ่มสองตัวได้คือค่าสหสัมพันธ์ (correlation)

หากเรากำหนดให้ X และ Y เป็นตัวแปรสุ่ม ค่าสหสัมพันธ์ของตัวแปรสุ่มทั้งสอง ρ_{XY} หรือ $\text{Cor}\{X, Y\}$ จะถูกนิยามดังต่อไปนี้

$$\begin{aligned}\rho_{XY} &= \text{Cor}\{X, Y\} = \frac{\sigma_{XY}}{\sigma_X \cdot \sigma_Y} \\ -1 &\leq \text{Cor}\{X, Y\} \leq 1\end{aligned}$$

หากเรามีชุดข้อมูลเป็นคู่อันดับ $\langle x, y \rangle$ เราสามารถใช้ฟังก์ชัน `corrcoef` เพื่อคำนวณหาค่าสหสัมพันธ์ระหว่างข้อมูลชุด \mathbf{x} และข้อมูลชุด \mathbf{y} ซึ่งจะได้ผลลัพธ์เป็นเมตริกซ์ดังต่อไปนี้


$$\text{corrcoef}(X, Y) = \begin{bmatrix} \text{Cor}\{X, X\} & \text{Cor}\{X, Y\} \\ \text{Cor}\{X, Y\} & \text{Cor}\{Y, Y\} \end{bmatrix}$$

ซึ่ง $\text{Cor}\{X, X\} = \text{Cor}\{Y, Y\} = 1$


เราจะใช้สมาชิกตัวที่ไม่ได้อยู่ในแนวทแยงเท่านั้นเนื่องจากค่าสหสัมพันธ์ของค่าเดียวกันจะมีผลเป็น 0 เสมอ

```
x = randn(1,100);
y = randn(1,100);
clf
ax = axes;
hold(ax, 'on')
grid(ax, 'on')
plot(ax, x, y, 'o')
axis(ax, 'equal')
```


```
title(ax, '$\rho_{XY}$ = 0', 'Interpreter', "latex")
```



```
x = randn(1,100);
y = x+0.5*(randn(size(x))-0.5);
clf
ax = axes;
hold(ax, 'on')
grid(ax, 'on')
plot(ax,x,y, 'o')
axis(ax, 'equal')
C = corrcoef(x,y);
title(ax, sprintf('$\rho_{XY}$ = %.3f', C(1,2)), 'Interpreter', "latex")
```



```
x = randn(1,100);
y = -x+0.1*(randn(size(x))-0.5);
clf
ax = axes;
hold(ax, 'on')
grid(ax, 'on')
plot(ax,x,y, 'o')
axis(ax, 'equal')
C = corrcoef(x,y);
title(ax,sprintf('$\\rho_{XY}$ = %.3f',C(1,2)), 'Interpreter', "latex")
```



สมบัติของค่าคาดหวังและค่าแปรปรวน (Properties of Expected Value & Variance)

ในกรณีที่เรามีค่าที่ไม่แน่นอนมากกว่าหนึ่งค่ามาผสมรวมกัน เราจะได้ค่าที่มีความไม่แน่นอนใหม่ ทั้งค่าคาดหวังและค่าแปรปรวนก็จะเปลี่ยนตามด้วย

หากกำหนดให้ X , Y , และ Z เป็นตัวแปรสุ่ม และ Z เป็นผลรวมเชิงเส้นของตัวแปร X และ Y ดังต่อไปนี้

$$Z = \alpha \cdot X + \beta \cdot Y$$

เราสามารถคำนวณหาค่าคาดหวังของตัวแปร Z ดังต่อไปนี้

$$\mu_Z = E\{Z\} = E\{\alpha \cdot X + \beta \cdot Y\} = \alpha \cdot \mu_X + \beta \cdot \mu_Y$$

นอกจากนี้ เราสามารถคำนวณหาค่าแปรปรวนของตัวแปร Z ดังต่อไปนี้

$$\sigma_Z^2 = \text{Var}\{Z\} = \alpha^2 \cdot \sigma_X^2 + 2\alpha\beta \cdot \sigma_{XY} + \beta^2 \cdot \sigma_Y^2$$

$$\sigma_Z^2 = \text{Var}\{Z\} = \alpha^2 \cdot \sigma_X^2 + 2\alpha\beta \cdot \rho_{XY} \cdot \sigma_X \cdot \sigma_Y + \beta^2 \cdot \sigma_Y^2$$

ความน่าจะเป็นและสัญญาณสุ่ม (Probability & Random Signal)

ตอนที่ 7 : เวกเตอร์สุ่ม (Random Vector)

ในกรณีที่เรามีตัวแปรสุ่มมากกว่าหนึ่งตัว เราสามารถจัดเรียงตัวแปรเหล่านี้ให้อยู่ในรูปของเวกเตอร์ เราจะกำหนดให้ ตัวแปรสุ่มทั้งหมด n ตัว และกำหนดให้เวกเตอร์สุ่ม (random vector) \mathbf{X} ประกอบไปด้วยสมาชิกดังนี้

$$\mathbf{X} = \begin{bmatrix} X_1 \\ \vdots \\ X_n \end{bmatrix}$$

หากตัวแปรสุ่มแต่ละตัวเป็นแบบไม่ต่อเนื่อง เราสามารถจำลองความไม่แน่นอนของเวกเตอร์ดังกล่าวได้ด้วยการแจกแจงซึ่งมีหลากหลายรูปแบบ ซึ่งส่วนนี้ต้องเขียนอยู่ในรูปของฟังก์ชันต่อไปนี้

$$P(\mathbf{X} \in A) = \sum_{\mathbf{x} \in A} \dots \sum f_{\mathbf{X}}(\mathbf{x})$$

โดยที่

$$\sum_{\text{for all } \mathbf{x}} \dots \sum f_{\mathbf{X}}(\mathbf{x}) = 1$$
$$0 \leq f_{\mathbf{X}}(\mathbf{x}) \leq 1$$

หากตัวแปรสุ่มแต่ละตัวเป็นแบบต่อเนื่อง เราสามารถเขียนฟังก์ชันแจกแจงได้ในรูปแบบดังต่อไปนี้

$$P(\mathbf{X} \in A) = \int^A \left\{ \dots \int \{f_{\mathbf{X}}(x_1, \dots, x_n)\} dx_1 \dots \right\} dx_n$$

โดยที่

$$\int_{-\infty}^{\infty} \left\{ \dots \int_{-\infty}^{\infty} \{f_{\mathbf{X}}(x_1, \dots, x_n)\} dx_1 \dots \right\} dx_n = 1$$
$$0 \leq f_{\mathbf{X}}(\mathbf{x}) \leq 1$$

ถึงแม้เวกเตอร์สุ่มเป็นเวกเตอร์หลัก (**column**) ในการเขียนสมการคณิตศาสตร์ แต่ในการเขียนโปรแกรมส่วนใหญ่ เรามักจะเรียกเวกเตอร์ให้เป็นแนวนอนเพื่อให้ค่าของเวกเตอร์นั้นเรียงกันได้ในแนวตั้ง เช่น กำหนดให้ตัวแปรสุ่มมีทั้งหมด 3 ตัวซึ่งจะถูกเก็บค่า/สุ่มค่าทั้งหมด 4 ครั้ง เราจะได้ชุดข้อมูลในรูปแบบดังกล่าว

$$\text{ข้อมูล} : [\mathbf{X}_{(1)} \quad \mathbf{X}_{(2)} \quad \mathbf{X}_{(3)} \quad \mathbf{X}_{(4)}]$$

ซึ่งสามารถเขียนเป็นโปรแกรมได้ดังนี้

```
X = rand(4,3) % uniform distribution between 0 & 1
```

```
X = 4x3
    0.4844    0.8296    0.2297
    0.0274    0.5490    0.5741
    0.9214    0.1532    0.9114
    0.5770    0.2602    0.5215
```

ค่าคาดหวังและเมตริกซ์แปรปรวน

ไม่ว่าการกระจายตัวจะเป็นอย่างไร เราสามารถที่จะจำลองลักษณะความไม่แน่นอนจากคุณลักษณะต่างๆได้ หนึ่งในนั้นก็คือค่าคาดหวังของเวกเตอร์สุ่มซึ่งเท่ากับเวกเตอร์ของค่าคาดหวังของแต่ละสมาชิกในเวกเตอร์

$$\mu_{\mathbf{X}} = E\{\mathbf{X}\} = \begin{bmatrix} E\{X_1\} \\ \vdots \\ E\{X_n\} \end{bmatrix}$$

นอกจากนี้ เรายังสามารถอธิบายความแปรปรวนของเวกเตอร์สุ่มได้ เช่นเดียวกันกับกรณีของตัวแปรสุ่มสองตัว เราจำเป็นต้องจับคู่ระหว่างตัวแปรสุ่มเพื่อคำนวณหาค่าแปรปรวนร่วมเฉลี่ยและยังต้องหาค่าแปรปรวนของแต่ละตัวแปรสุ่มอีกด้วย

หากเรามีจำนวนตัวแปรสุ่มทั้งหมด n ตัวด้วยกัน เราจะมีค่าแปรปรวนทั้งหมด n ตัว ($\sigma_{X_i}^2$) และค่าแปรปรวนร่วมเกี่ยวเป็นจำนวนทั้งหมด $n \cdot (n - 1)$ ตัว ($\sigma_{X_i X_j}$) เพื่อความสะดวกในการเขียนอธิบาย เราสามารถจัดค่าแปรปรวนทั้งหมดนี้ให้อยู่ในรูปของเมทริกซ์ดังต่อไปนี้

$$\mathbf{K}_{\mathbf{X}} = \text{Cov}\{\mathbf{X}, \mathbf{X}\} = \begin{bmatrix} \sigma_{X_1}^2 & \sigma_{X_1 X_2} & \cdots & \sigma_{X_1 X_n} \\ \sigma_{X_1 X_2} & \sigma_{X_2}^2 & \cdots & \sigma_{X_2 X_n} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{X_1 X_n} & \sigma_{X_2 X_n} & \cdots & \sigma_{X_n}^2 \end{bmatrix}$$

เมทริกซ์นี้ถูกเรียกว่า เมทริกซ์ค่าแปรปรวน-ค่าแปรปรวนร่วมเกี่ยว หรือเรียกสั้นๆว่า เมตริกซ์ค่าแปรปรวนร่วมเกี่ยว (variance-covariance matrix/covariance matrix) ซึ่งเมทริกซ์นี้จะมีคุณสมบัติดังต่อไปนี้

$$\mathbf{v}^T \cdot \mathbf{K}_{\mathbf{X}} \cdot \mathbf{v} \geq 0$$

$$\mathbf{K}_{\mathbf{X}} = \mathbf{K}_{\mathbf{X}}^T$$

$$\text{Cov}\{\mathbf{A} \cdot \mathbf{X} + \mathbf{b}, \mathbf{A} \cdot \mathbf{X} + \mathbf{b}\} = \mathbf{A} \cdot \mathbf{K}_{\mathbf{X}} \cdot \mathbf{A}^T$$

สองสมบัติแรกแสดงให้เห็นว่าเราไม่สามารถที่จะเลือกจำลองเมตริกซ์ค่าแปรปรวนแบบสุ่มสี่สุ่มห้าได้

หากเรามีชุดข้อมูล เราสามารถใช้ฟังก์ชัน `cov` ของ **MATLAB** ในการหาเมตริกซ์ค่าแปรปรวนนี้ได้เลย

```
X_U = rand(100,2);
X = [X_U 2*X_U+0.1*(rand(size(X_U))-0.5)];
```

```
K = cov(X)
```

```
K = 4x4
    0.0835    -0.0130     0.1675    -0.0251
   -0.0130     0.0865    -0.0272     0.1725
    0.1675    -0.0272     0.3370    -0.0530
   -0.0251     0.1725    -0.0530     0.3450
```

```
R = corrcoef(X); % เมตริกซ์สหสัมพันธ์
```

การแจกแจงแบบปรกติหลายตัวแปร (Multivariate Normal Distribution)


การแจกแจงที่มักจะถูกใช้บ่อยครั้งในการจำลองความไม่แน่นอนที่มีหลายตัวแปรคือการแจกแจงแบบปรกติสำหรับหลายตัวแปร (Multivariate Normal Distribution) ซึ่งสามารถเขียนเป็นฟังก์ชันได้ดังนี้

$$f_{\mathbf{X}}(\mathbf{x}) = \frac{1}{\sqrt{(2\pi)^n |\mathbf{K}_{\mathbf{X}}|}} e^{-\frac{1}{2}(\mathbf{x}-\mu_{\mathbf{X}})^T \mathbf{K}_{\mathbf{X}}^{-1} (\mathbf{x}-\mu_{\mathbf{X}})}$$

การแจกแจงนี้ถูกใช้เป็นแบบจำลองความไม่แน่นอนของพฤติกรรมหลายอย่างในระบบหุ่นยนต์เช่นความไม่แน่นอนของตำแหน่งในพื้นที่ **2 มิติ** หรือความไม่แน่นอนของค่าต่างๆที่อ่านได้จากเซนเซอร์

เราสามารถใช้ฟังก์ชัน `mvnrnd` ของ **MATLAB** ในการสุ่มค่าของตัวแปรดังต่อไปนี้

```
x_est = [3;4];
var = [2;1];
covar = 2*sqrt(abs(prod(var)))*(rand-1/2);
P = diag(var)+[0 covar; covar 0]; % must be semi-positive definite
X = mvnrnd(x_est,P,100);
clf
ax = axes;
hold(ax,'on')
grid(ax,'on')
plot(ax,X(:,1),X(:,2),'+')
axis(ax,'equal')
```



ความน่าจะเป็นและสัญญาณสุ่ม (Probability & Random Signal)

ตอนที่ 8 : สัญญาณสุ่ม (Random Signal)

เราได้ศึกษาเกี่ยวกับสัญญาณซึ่งเป็นค่าที่แปรเปลี่ยนไปตามเวลา(หรือปริภูมิ) ซึ่งเราจะกำหนดให้ตัวแปร t เป็นตัวแปรอิสระที่บ่งบอกถึงเวลา หากสัญญาณนั้นมีความไม่แน่นอน เราจะเรียกสัญญาณดังกล่าวว่า สัญญาณสุ่ม (random signal)

หากเรามองในมุมมองของสัญญาณที่เกิดจากการทดลอง สัญญาณสุ่มคือสัญญาณที่ไม่เหมือนเดิมเมื่อทำการทดลองซ้ำ

การจำลองข้อมูลการสุ่มของสัญญาณสุ่ม

กำหนดให้เราสร้างชุดข้อมูลเสมือนของสัญญาณสุ่มขึ้นมา

โดยที่สัญญาณสุ่มจะมีทั้งหมด n ช่อง/ตัว

$$\mathbf{X}[k] : \mathbf{Z} \rightarrow \mathfrak{R}^n$$

และแต่ละช่องจะถูกเก็บค่าในช่วงเวลาทั้งหมด N ค่า (โดยสุ่มตัวอย่าง หรือ sample)

$$\bar{\mathbf{X}} = [\mathbf{X}[1] \quad \cdots \quad \mathbf{X}[N]] = \begin{bmatrix} X_1[1] & \cdots & X_1[N] \\ \vdots & \ddots & \vdots \\ X_n[1] & \cdots & X_n[N] \end{bmatrix}$$

และเราเก็บค่าทั้งหมด M รอบ

เราสามารถเก็บข้อมูลดังกล่าวในรูปของ **array** หลายมิติได้ โดยที่เราจะกำหนดให้ มิติที่หนึ่งคือเวลา (1 ถึง N) มิติที่สองคือตัวแปร (1 ถึง n) และมิติที่สามคือครั้งในการเก็บข้อมูล (1 ถึง M) ซึ่งเราเขียนเป็น pseudo-code คร่าวๆ ได้ดังนี้

```
t = (0:dt:dt*(N-1));
dataset = zeros(N,n,M);
for k = 1:M
    dataset(:, :, k) = run_experiment();
end
```

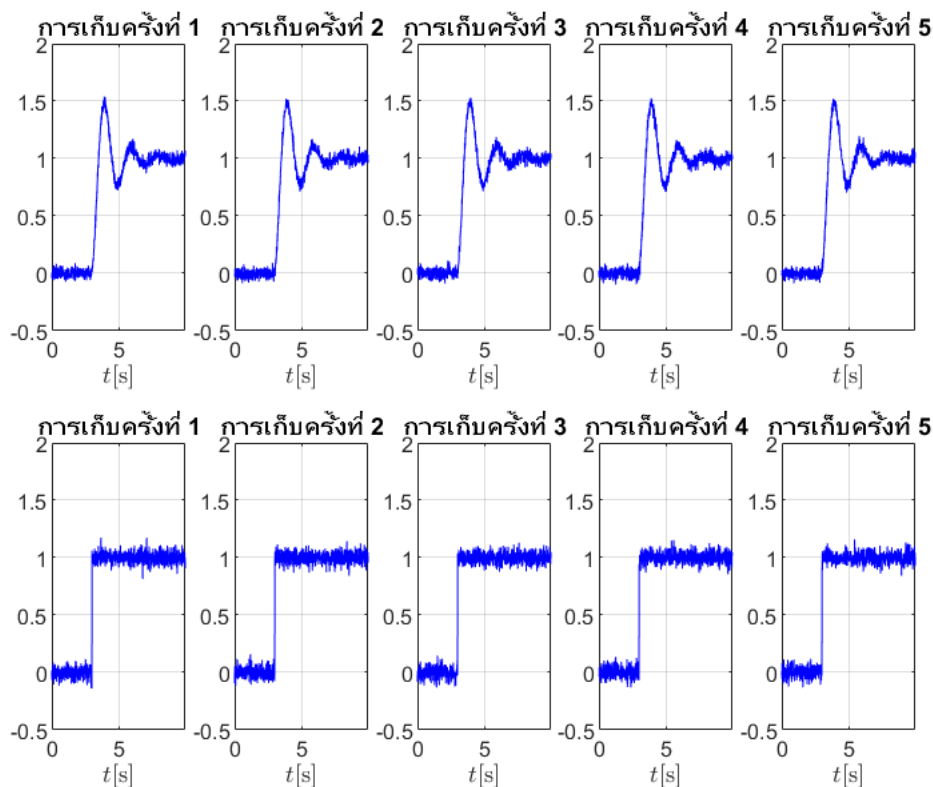
```
% การจำลองข้อมูล (ไม่ใช่ข้อมูลจริง)
N = 1000;
f_s = 100;
f = 0.5;
w = 2*pi*f;
dt = 1/f_s;
t = (0:dt:dt*(N-1));
y_1 = (1-exp(-0.75*(t-3))).*cos(w*(t-3)).*(t>3);
y_2 = (t>3);
n = 2;
M = 5;
dataset = zeros(N,n,M);
var = [0.001;0.002];
covar = 2*sqrt(abs(prod(var)))*(rand-1/2);
P_sim = diag(var)+[0 covar; covar 0];
for k = 1:M
    dataset(:, :, k) = [y_1' y_2'] + mvnrnd([0;0],P_sim,N);
end
```



```

clf
for j = 1:n
    for k = 1:M
        ax = subplot(n,M,M*(j-1)+k);
        plot(ax,t,dataset(:,j,k), 'b')
        axis(ax,[min(t) max(t) -0.5 2])
        grid(ax,'on')
        xlabel('$t[s]$', 'Interpreter', "latex")
        title(ax,sprintf('การเก็บครั้งที่ %d',k))
    end
end

```



ค่าเฉลี่ย

เมื่อเราทดลองและเก็บผลหลายครั้ง เราต้องมั่นใจว่าการทดลองแต่ละครั้งนั้นถูกควบคุมให้เงื่อนไขต่างๆเป็นเหมือนกัน ผลลัพธ์ที่ได้มานั้นจะมีความแปรปรวนในแต่ละรอบการทดลอง เราสามารถหาค่าเฉลี่ยของการทดลองได้โดยการนำผลของการทดลองแต่ละครั้งมาหารเฉลี่ยกัน แต่เราจะไม่นำค่าในช่วงเวลามาหารเฉลี่ยกัน หรือกล่าวอีกอย่างคือ เราจะไม่นำค่าที่มีเวลาเป็น คณะเวลามาหารเฉลี่ยรวมกัน

$$\mu_X[k] = E\{X[k]\} = \frac{1}{M} \sum_{j=1}^M \{X^{(j)}[k]\}$$

โดยที่ $X^{(j)}[k]$ คือค่าของตัวแปรสุ่มทุกตัว ณ การทดลองที่ j และเวลาที่ k


เราสามารถใช้ฟังก์ชัน **mean** ในการหาค่าเฉลี่ยโดยที่เราจะเฉลี่ยข้อมูลในมิติที่สาม เราสามารถคำนวณและกราฟค่าเฉลี่ยและข้อมูลได้ดังต่อไปนี้

N = 1000;

```

f_s = 100;
f = 0.5;
w = 2*pi*f;
dt = 1/f_s;
t = (0:dt:dt*(N-1));
y_1 = (1-exp(-0.75*(t-3)).*cos(w*(t-3))).*(t>3);
y_2 = (t>3);
n = 2;
M = 1000;
dataset = zeros(N,n,M);
var = [0.001;0.002];
covar = 2*sqrt(abs(prod(var)))*(rand-1/2);
P_sim = diag(var)+[0 covar; covar 0];
for k = 1:M
    dataset(:, :, k) = [y_1' y_2'] + mvnrnd([0;0], P_sim, N);
end
mu = mean(dataset, 3);
clf;
ax = axes;
hold(ax, 'on')
plot(ax, t, dataset(:, 1, 1), 'b')
plot(ax, t, mu(:, 1), 'r', 'LineWidth', 2)

```



เมตริกซ์ค่าแปรปรวนร่วมเกี่ยว

เช่นเดียวกับการหาค่าเฉลี่ย เราสามารถคำนวณหาเมตริกซ์ค่าแปรปรวนร่วมเกี่ยวของสัญญาณได้ โดยคำนวณหาเมตริกซ์ในแต่ละเวลา k ผลที่ได้คือเมตริกซ์ $\mathbf{K}_X[k]$ ทั้งหมด N ตัว

$$\mathbf{K}_X[k] = \text{Cov}\{X[k], X[k]\}$$

หากในทุกเวลา k เมตริกซ์แต่ละตัวมีค่าที่ใกล้เคียงกัน เราสามารถประมาณได้ว่าคุณลักษณะทางสถิติของทั้งสัญญาณนั้นไม่แปรเปลี่ยน หรือเรียกอีกอย่างได้ว่า สัญญาณนั้นเป็นสัญญาณนิ่ง (stationary signal)

เราสามารถประมาณได้ว่าเมตริกซ์ค่าแปรปรวนร่วมแก้ไขได้ดังต่อไปนี้

$$\mathbf{K}_X \approx \frac{1}{N} \sum_{k=1}^N \mathbf{K}_X[k]$$

เราสามารถเขียนโปรแกรมจำลองการทดลองได้ดังต่อไปนี้

```
N = 1000;
f_s = 100;
f = 0.5;
w = 2*pi*f;
dt = 1/f_s;
t = (0:dt:dt*(N-1));
y_1 = (1-exp(-0.75*(t-3)).*cos(w*(t-3))).*(t>3);
y_2 = (t>3);
n = 2;
M = 1000;
dataset = zeros(N,n,M);
var = [0.001;0.002];
covar = 2*sqrt(abs(prod(var)))*(rand-1/2);
P_sim = diag(var)+[0 covar; covar 0];
for k = 1:M
    dataset(:, :, k) = [y_1' y_2'] + mvnrnd([0;0], P_sim, N);
end
mu = mean(dataset, 3);
K_XX = zeros(n);
for j = 1:N
    % for each t, compute covariance matrix
    K_XX = K_XX + cov(permute(dataset(j, :, :), [3, 2, 1]));
end
K_XX = K_XX/N
```

```
K_XX = 2×2
    0.0010    0.0002
    0.0002    0.0020
```

เราสามารถนำเมตริกซ์ดังกล่าวเพื่ออธิบายความไม่แน่นอนของค่าที่วัดได้จากเซนเซอร์และนำไปใช้ต่อไปในการทำตัวกรองคาลมาน (Kalman Filter)